



# **Exploración: Exploración de modelos de inteligencia artificial en procesos de diseño de materiales.**

**Proyecto Integrador**

Patrocinadores:

Dr. Juan Arturo Nolazco Flores

Dr. Samuel Lara Ávila

**Integrantes:**

**Javier González Aces - A01274650**

**José Alejandro Cortés Pérez - A01795033**

**Osiris Xcaret Saavedra Solís - A01795992**

**Fecha de entrega: 01 de febrero del 2026**

## Contents

|                                          |    |
|------------------------------------------|----|
| Herramientas de trabajo.....             | 4  |
| Modelos.....                             | 4  |
| Utilerías .....                          | 4  |
| Infraestructura .....                    | 5  |
| Comparativa.....                         | 5  |
| Modelos de generación .....              | 5  |
| Modelos Alternativos .....               | 6  |
| Datos de entrada .....                   | 6  |
| Datos de salida .....                    | 7  |
| Librerías y dependencias clave.....      | 7  |
| Modelos de simulación .....              | 8  |
| Modelos alternativos .....               | 8  |
| Datos de entrada .....                   | 9  |
| Datos de salida .....                    | 9  |
| Librerías y dependencias clave.....      | 9  |
| Técnicas de análisis de resultados ..... | 10 |
| Conclusiones .....                       | 11 |

## Introducción

En un proyecto convencional de machine learning supervisado, un Análisis Exploratorio de Datos (EDA) es un paso fundamental debido a que el desempeño del modelo depende directamente de comprender, limpiar y transformar los datos de entrenamiento. Sin embargo, el presente proyecto no se basa en la construcción de un modelo desde cero, sino en la aplicación, adaptación y evaluación de modelos avanzados ya entrenados por laboratorios especializados en inteligencia artificial.

Es importante mencionar que:

- No se entrena un modelo propio.
- El enfoque de este proyecto gira en torno a modelos generativos, modelos de simulación y análisis de resultados.

Un EDA formal (estructura de datos, análisis univariante, multivariante, preprocesamiento) pierde relevancia metodológica y no representa adecuadamente las etapas reales del flujo de trabajo del proyecto.

Por ello, se propone reemplazar las secciones estándar del EDA por apartados que sí reflejan el proceso investigativo y técnico del proyecto, manteniendo al mismo tiempo rigor metodológico y claridad en la presentación.

Las secciones quedan modificadas de la siguiente manera:

| <b>Sección Original</b> | <b>Sección Propuesta</b>           |
|-------------------------|------------------------------------|
| Estructura de los datos | Herramientas seleccionadas         |
| Análisis univariante    | Modelos de generación              |
| Análisis multivariante  | Modelos de simulación              |
| Preprocesamiento        | Técnicas de análisis de resultados |
| Conclusiones            | Conclusiones                       |

## Herramientas de trabajo

En esta sección se describen los modelos, infraestructura y utilerías que se utilizan en este proyecto al momento de redactar este documento como un símil a la sección de materiales y método que se encuentra en un artículo convencional.

### Modelos

Para iniciar la etapa de validación de resultados se utilizan modelos de Microsoft Research:

- MatterGen: Es un modelo de difusión que imagina nuevos materiales a partir de algunas restricciones como la composición química, la banda prohibida y otras restricciones. El modelo genera estructuras cristalinas que representan al material y pueden ser simuladas para predecir sus propiedades y características físicas.
- MatterSim: Es un modelo avanzado de deep learning diseñado para simular las propiedades de materiales en un amplio rango de elementos, temperaturas y presiones. El modelo utiliza técnicas de vanguardia en aprendizaje profundo para ofrecer alta precisión y eficiencia en simulaciones atomísticas, lo que lo convierte en una herramienta valiosa para investigadores en el campo de la ciencia de materiales.

Modelos adicionales serán explorados en semanas próximas para juzgar su rendimiento contra los mencionados anteriormente.

El hecho de tener las capacidades de simular materiales a nivel computacional en específico del grafeno permite el estudio de las propiedades del material, así como la interacción de este con otros materiales dando la posibilidad de estudiar nuevas combinaciones, así como los cambios que éstos presentan al realizar combinaciones y cambios de estructura o de dopaje en distintas cantidades.

Dentro de las metas principales se encuentra la aplicación de las nuevas tecnologías de inteligencia artificial para el desarrollo y el estudio materiales, así como encontrar nuevas combinaciones de tener la capacidad de eliminar o aceptar los resultados que generen los distintos modelos.

### Utilerías

| Utilería/Herramienta | Uso                                                                                    |
|----------------------|----------------------------------------------------------------------------------------|
| Python               | Entorno y tecnología de ejecución de los modelos de IA.                                |
| Vesta                | Visualización de estructuras cristalinas                                               |
| Git/Git-LFS          | Gestión de control de versiones y descarga de los pesos pre-entrenados de los modelos. |

## Infraestructura

|                            |                  |      |                            |                  |              |                    |             |  |
|----------------------------|------------------|------|----------------------------|------------------|--------------|--------------------|-------------|--|
| NVIDIA-SMI 535.274.02      |                  |      | Driver Version: 535.274.02 |                  |              | CUDA Version: 12.2 |             |  |
| GPU                        | Name             |      | Persistence-M              | Bus-Id           | Disp.A       | Volatile           | Uncorr. ECC |  |
| Fan                        | Temp             | Perf | Pwr:Usage/Cap              |                  | Memory-Usage | GPU-Util           | Compute M.  |  |
|                            |                  |      |                            |                  |              |                    | MIG M.      |  |
| 0                          | NVIDIA RTX A6000 |      | Off                        | 00000000:AC:00.0 | Off          |                    | Off         |  |
| 30%                        | 31C              | P8   | 23W / 300W                 | 1MiB / 49140MiB  |              | 0%                 | Default     |  |
|                            |                  |      |                            |                  |              |                    | N/A         |  |
| 1                          | NVIDIA RTX A6000 |      | Off                        | 00000000:CA:00.0 | Off          |                    | Off         |  |
| 30%                        | 31C              | P8   | 19W / 300W                 | 1MiB / 49140MiB  |              | 0%                 | Default     |  |
|                            |                  |      |                            |                  |              |                    | N/A         |  |
| Processes:                 |                  |      |                            |                  |              |                    |             |  |
| GPU                        | GI               | CI   | PID                        | Type             | Process name |                    | GPU Memory  |  |
|                            | ID               | ID   |                            |                  |              |                    | Usage       |  |
| No running processes found |                  |      |                            |                  |              |                    |             |  |

## Comparativa

Se han considerados dos posibles enfoques para atacar la problemática del proyecto, los modelos de simulación y los modelos generativos. Cada uno de ellos nos presenta la respuesta a una pregunta distinta. Para los modelos de simulación la pregunta central es *"Dado que el mundo físico obedece determinadas leyes, ¿qué material es posible sintetizar?"*, mientras que para los modelos generativos la pregunta central es *"Dados muchos ejemplos de materiales ¿qué nuevos materiales se pueden generar?"*. Analizando ambas preguntas centrales, podemos observar que no compiten entre sí, si no que se complementan, funcionando para objetivos distintos.

## Modelos de generación

Los modelos de generación se utilizan para el diseño de materiales inorgánicos (generalmente) a través de la tabla periódica. Un modelo generativo aprende de una distribución de datos dada, en este caso estructuras, composiciones y propiedades, para generar nuevos ejemplos sin resolver explícitamente ecuaciones físicas. Existen varios tipos de modelos de esta índole, aprovechando

distintas técnicas de la inteligencia artificial, como difusores, VAE (Variational autoencoders) y redes neuronales basadas en grafos.

En nuestro estudio nos enfocamos en primera instancia sobre MatterGen, que puede ser afinado para dirigir la generación hacia la restricción de propiedades específicas. Se utiliza una métrica S.U.N. para juzgar el rendimiento de estos modelos. Las siglas significan Stable, Unique, Novel. En el caso de MatterGen, se estima un S.U.N. de 38.57%.

Las ventajas de los modelos generativos para este enfoque son:

- **Exploración masiva del espacio químico:** Se puede generar una gran cantidad de materiales candidatos de manera rápida.
- **Enfoque flexible:** Atacan la pregunta "*¿Qué estructura necesito para obtener determinadas propiedades físicas?*"
- **Costos computacionales bajos:** Una vez que el modelo ha sido entrenado, generar muestras presenta un bajo costo computacional.

Mientras que las desventajas son:

- **No garantizan validez física:** Los modelos generativos pueden alucinar, generando estructuras inestables o enlaces imposibles.
- **Fuerte dependencia de los datos de entrenamiento:** Si el conjunto de datos de entrenamiento no es variado y es pobre, los resultados arrojados por el modelo también lo serán.
- **Interpretabilidad limitada:** Una vez obtenidos los resultados o las propuestas del modelo, es difícil determinar cómo fue que el modelo llegó a una estructura viable.

## Modelos Alternativos

| Modelo    | S.U.N. | Observación            |
|-----------|--------|------------------------|
| DiffCSP   | 33.27% | Similar, dataset menor |
| CDVAE     | 13.99% | Autoencoder variable   |
| MatterGPT | N/A    | Secuencial             |

## Datos de entrada

El análisis para la modelación de los materiales y sus posibles combinaciones se encuentra que la variable principal es el material en sí mismo así como las posibles combinaciones que puedan surgir con otros materiales siendo estos de primera instancia el material inicial en este caso el grafeno con la combinación del material secundario o incluso mayor número de materiales pero siendo de especial interés el estudio de dos o uno como primer paso de desarrollo, dentro de las variables se encuentran de igual forma las propiedades físicas y químicas de los materiales así como las variables de estas mismas que puedan ser simuladas.

Los datos de entrada que maneja MatterSim son de dos tipos: atributos de ejecución y propiedades condicionantes. Los que hemos usado hasta ahora son:

Atributos de ejecución:

- Batch\_size
- Num-batches
- Difusión\_guidance\_factor

Propiedades condicionantes:

- Chemical\_system
- Band\_gap

## Datos de salida

Dentro de los datos de salida están factores como lo son DFT para determinar las propiedades físicas y químicas de los materiales de igual forma otras de las variables de gran interés para el desarrollo de este tipo de materiales son las propiedades cuánticas que se presentan como la salida de dichas combinaciones, dentro de las variables se incluye de igual forma no resultados de estas mismas por ejemplo las variaciones en los poros, resultados para spintrónica, interacciones de ángulos mágicos, efectos cuánticos como lo son los conos de Dirac, efecto Hall, comportamiento de plasmones, tunelamiento de Klein y fase de Berry, estados de los bordes.

Los datos de salida se producen en tres formatos distintos:

1. **Formato .cif:** Crystallographic Information Files, estandar para compartir estructuras materiales.
2. **Formato .xyz:** Archivo simple de coordenadas
3. **Summary .csv:** Contiene propiedades (estabilidad, densidad magnética, etc) si la generación fue condicionada.

## Librerías y dependencias clave

Estos modelos utilizan una serie de librerías especializadas para aprendizaje profundo y ciencia de materiales. En el caso de MatterGen se usa:

Aprendizaje profundo:

- PyTorch
- Lightning (Antes PyTorch Lightning)

Ciencia de materiales:

- Pymatgen
- ASE

# Modelos de simulación

Un modelo de simulación es un modelo basado en leyes físicas explícitas, que describe cómo evolucionan los átomos, electrones y las fases de un material a partir de ecuaciones fundamentales. Un ejemplo de estos enfoques, son el DFT (Density Functional Theory), Molecular Dynamics (MD), simulaciones Monte Carlo, etc. Los modelos atomísticos son herramientas computacionales que simulan y predicen el comportamiento de los materiales a nivel atómico. Permiten calcular propiedades como:

- Energía de configuraciones atómicas
- Fuerzas entre átomos
- Estrés/deformación en materiales
- Dinámica estructural a lo largo del tiempo

Estos modelos son esenciales para comprender las propiedades de los materiales sin necesidad de realizar experimentos costosos.

Los modelos de simulación presentan ventajas y desventajas para este enfoque. Las ventajas son:

- **Interpretabilidad:** Todo resultado tiene una explicación física directa.
- **Extrapolación fuerte:** Se pueden explorar condiciones que son difíciles de alcanzar de manera experimental.
- **Validez científica:** Son aceptados como evidencia en artículos de investigación y patentes al utilizar leyes físicas conocidas.

Desventajas:

- **Costo computacional alto:** El uso de métodos como DFT son costosos computacionalmente, por lo que las simulaciones se deben limitar a sistemas pequeños.
- **Escalabilidad limitada:** De la misma manera que el punto anterior, es complicado explorar espacios grandes de composición o procesos, debido a que las simulaciones se vuelven lentas.
- **Enfoque rígido:** El enfoque de los modelos de simulación va orientado a responder la pregunta *"Dadas las leyes físicas, una determinada estructura tendrá las siguientes propiedades físicas."*, que presenta poca flexibilidad para responder la pregunta *"¿Qué estructura necesito para obtener determinadas propiedades físicas?"*

## Modelos alternativos

| Modelo | Arquitectura            | Ventaja                                 |
|--------|-------------------------|-----------------------------------------|
| CHGNet | Modelo basado en grafos | Para estructuras estables               |
| M3GNet | Modelo basado en grafos | Modelo en el que se basa MatterSim      |
| MACE   |                         | Preciso pero computacionalmente costoso |



## Datos de entrada

MatterSim toma como entrada archivos de estructura atómica en formatos estándar de computación química como lo son:

- **.xyz:** Archivos de coordenadas
- **.cif:** Archivos de información de cristales
- **.vasp:** Archivos VASP
- **.traj:** Archivos de trayectorias ASE
- Representaciones en JSON de objetos ASE

## Datos de salida

- Cálculos
  - Energía
  - Fuerzas
  - Estrés
- Relajaciones estructurales
  - Archivos de geometría relajada
  - Trayectorias de relajación
  - Energías y Fuerzas finales
- Dinámica Molecular
  - Trayectorias y propiedades termodinámicas
- Cálculo de fonón
  - Propiedades vibracionales

## Librerías y dependencias clave

Pila de simulación de materiales:

- └─ ASE (manejo de estructuras)
- └─ Pymatgen (análisis de materiales)
- └─ Phonopy (propiedades vibracionales)
- └─ MP-API (acceso a bases de datos)

Pila de ML/DL:

- └─ PyTorch (framework base)
- └─ PyTorch Geometric (redes neuronales de grafos)

└— E3NN (equivarianza)

└— Utilidades de entrenamiento (EMA, métricas)

## Técnicas de análisis de resultados

El análisis de resultados en este proyecto se centra en evaluar la calidad, estabilidad y validez física de los materiales generados mediante modelos de generación y simulación.

El objetivo es determinar si las estructuras generadas son estables, coherentes con la física del sistema y consistentes con las propiedades condicionantes utilizadas como entrada.

### 1. Validación estructural

La primera etapa del análisis consiste en evaluar la viabilidad estructural de los materiales generados. Para ello se emplean técnicas como:

1. Verificación de simetría cristalina: se evalúa si la estructura generada respeta las simetrías correspondientes a la composición química y al tipo de celda esperada.
2. Detección de distancias atómicas no físicas: se inspeccionan enlaces y distancias interatómicas para identificar solapamientos o separaciones imposibles.
3. Coherencia geométrica: se revisa la continuidad de la estructura, la configuración de la red y la presencia de posibles defectos generados por ruido del modelo.

Estas evaluaciones permiten descartar estructuras geométricamente incorrectas antes de someterlas a simulación.

### 2. Análisis energético

La estabilidad de un material está fuertemente vinculada con su energía total. Con los modelos de simulación se evalúan:

1. Energía potencial total del sistema
2. Energías relativas entre configuraciones similares
3. Energía de formación, cuando la composición lo permite

Una energía más baja generalmente implica un estado más estable. Esta métrica es fundamental para determinar si una estructura generada es físicamente plausible.

### 3. Análisis de fuerzas y relajación

Los modelos como MatterSim permiten calcular:

- Fuerzas atómicas sobre cada átomo
- Trayectorias de relajación estructural
- Evolución del sistema hacia un mínimo de energía

Durante este proceso se monitorea:

- Magnitud de fuerzas residuales
- Convergencia hacia una estructura estable
- Cambios en la geometría respecto a la estructura generada inicialmente

Si la relajación converge de forma suave y con pequeñas modificaciones estructurales, la estructura generada es consistente desde el punto de vista atomístico.

#### 4. Propiedades físico-químicas derivadas

Cuando el modelo lo permite, se analizan propiedades generadas o simuladas como:

- Band gap (si es parte de las restricciones)
- Densidad magnética o electrónica
- Tensor de estrés
- Propiedades vibracionales básicas

Estas propiedades se comparan con valores esperados según:

- La composición química
- El tipo de estructura
- Las restricciones aplicadas en la generación

Esto permite validar que el material generado no sólo es estable, sino también coherente con las características objetivo.

#### 5. Visualización y análisis cualitativo

Finalmente, se realiza un análisis cualitativo mediante herramientas de visualización como VESTA o ASE Viewer, lo que facilita:

- Identificar patrones estructurales
- Observar defectos o irregularidades
- Comparar configuraciones relajadas vs. generadas
- Presentar resultados de manera clara e interpretativa

## Conclusiones

Dentro de los principales retos para el proyecto implica el utilizar las librerías de uso científico y aplicadas en la simulación de materiales que tienden a contener los datos de las diferentes propiedades de cada uno de los materiales así como la integración de modelos generativos de materia que permitan simular dichos materiales con un mayor detalle y de igual forma den paso al desarrollo y entendimiento de nuevos materiales así como sus posibles propiedades y descarte y asimilación de las propiedades y beneficios que estos mismos tienen con la posibilidad de aplicarlos

aún entorno de laboratorio real a partir de los simulado. De la misma manera, se debe buscar un balance entre los enfoques que ofrecen los modelos generativos y los modelos de simulación, proponiendo el siguiente pipeline híbrido:

