



**Tecnológico
de Monterrey**

**Baseline: Exploración de modelos de
inteligencia artificial en procesos de diseño
de materiales.**

Proyecto Integrador

Patrocinadores:

Dr. Juan Arturo Nolasco Flores

Dr. Samuel Lara Ávila

Integrantes:

Javier González Aces - A01274650

José Alejandro Cortés Pérez - A01795033

Osiris Xcaret Saavedra Solís - A01795992

Fecha de entrega: 15 de febrero del 2026

¿Qué algoritmo se puede usar como baseline para predecir las variables objetivo?

En el trabajo elaborado hasta el momento para el modelo DiffCSP, el objetivo del entrenamiento es predecir el ruido gaussiano ε , añadido a las coordenadas fraccionarias durante el proceso forward, dadas x_t , z y t (pérdida MSE), que es un objetivo típico de la difusión.

Dado el contexto anterior, se proponen los algoritmos baseline siguientes:

Baseline 1: Predicción nula ($\varepsilon = 0$)

- Representa el piso mínimo teórico.
- Permite medir una mejora porcentual.
- No aprende estructura alguna.

Baseline 2: Regresión Ridge

- Se entrena un modelo lineal regularizado que predice $\varepsilon = f(x_t, z, t)$, siendo x_t las coordenadas perturbadas, z el número atómico y t el paso temporal normalizado.
- Permite la interpretabilidad, así como un análisis de importancia de las variables.

Baseline 3: Generativo físico

- Consiste en una generación aleatoria con reglas de validez simples (sin usar ML) para medir la tasa de estructuras físicamente plausibles y comparar contra el modelo aprendido.

Como baseline formal se propone:

Ridge Regression + Predicción Nula + Modelo DDPM simplificado

El enfoque anterior establece un marco comparativo claro antes de usar una arquitectura más compleja.

¿Se puede determinar la importancia de las características?

Si, se puede determinar de dos maneras:

Baseline Ridge

La importancia se obtiene directamente de los coeficientes del modelo, en donde las coordenadas perturbadas x_t muestran la mayor contribución, el tiempo de difusión t tiene un impacto consistente y el número atómico z aporta señal moderada, lo que indica que el modelo aprende dependencias estadísticas básicas.

Modelo Dummy denoiser

Se utilizaron ablation studies (es decir, eliminando variables) y comparación de desempeño al remover z o t . Es gracias a lo anterior que se observó que eliminar x_t degrada completamente el modelo, eliminar t reduce la precisión y eliminar z impacta menos, lo que sugiere que el baseline aún no modela química compleja.

En conclusión, es posible determinar importancia de variables, pero el baseline actual solo captura relaciones estadísticas simples, no interacciones físicas profundas.

¿El modelo está sub/sobreajustando los datos de entrenamiento?

Tomando en cuenta que la evaluación es generada comparando MSE_eps en train vs validation, Validity rate en train vs validation y Error RDF en train vs validation, podemos observar que:

- Si $MSE(train) \approx MSE(val)$ y ambos son relativamente altos entonces hay subajuste.
- Si $MSE(train) \ll MSE(val)$ entonces hay Sobreajuste.

En el baseline simplificado, generalmente se observa un leve subajuste debido a una arquitectura simple, ausencia de modelado geométrico y el nulo uso de vecindarios, lo que es esperado en un baseline inicial.

¿Cuál es la métrica adecuada para este problema de negocio?

Recordemos que el objetivo final no es solo predecir el ruido gaussiano, si no también generar estructuras cristalinas físicamente plausibles, por lo que la métrica más adecuada debe tener dos niveles:

Métrica ML:

- MSE de predicción de ruido (MSE_eps)
- Mejora porcentual contra baseline nulo.

Métricas estructurales (el equivalente al “negocio” real)

- Validity Rate (% de estructuras sin colisiones)
- Distancia mínima interatómica promedio.
- Error en densidad.
- Distancia RDF (similitud estructural)

Podemos hacer principal énfasis en validity rate + RDF error, ya que reflejan calidad estructural y coherencia física.

¿Cuál debería ser el desempeño mínimo por obtener?

Se realiza una propuesta a manera de criterio mínimo para considerar que el modelo aprende de manera real:

- Mejora $\geq 10\%$ sobre el baseline nulo en MSE_eps
- Validity Rate de al menos el doble que la generación aleatoria.
- RDF Error menor que el random baseline.
- No presentar sobreajuste (es decir, $tran \approx val$)

Conclusión

El baseline establece un marco cuantitativo sólido a la vez que permite justificar el uso de modelos más avanzados, separando aprendizaje estadístico de modelado físico.