



Conclusiones: Exploración de modelos de inteligencia artificial en procesos de diseño de materiales.

Proyecto Integrador

Patrocinadores:

Dr. Juan Arturo Nolasco Flores

Dr. Samuel Lara Ávila

Integrantes:

Javier González Aces - A01274650

José Alejandro Cortés Pérez - A01795033

Osiris Xcaret Saavedra Solís - A01795992

Fecha de entrega: 08 de marzo del 2026

Síntesis de los objetivos de proyecto	3
Antecedentes	3
Tesis central	4
Retos en la generación de materiales con modelos de difusión	5
Proceso de trabajo para la generación y filtrado de materiales en automático	6
Inferencia	7
Generación	7
Simulación	7
Evaluación	7
Almacenamiento	7
Datos de cristales	7
Blobs	7
Gestor	7
Gestión y configuración de proceso	7
Visualización y anotación de resultados	7
Hallazgos claves y conclusiones	8
Trabajo futuro	8

Síntesis de los objetivos de proyecto

El objetivo principal de este proyecto es la exploración de modelos basados en algoritmos de inteligencia artificial para la generación y evaluación de materiales.

La colaboración del Tecnológico de Monterrey y el departamento de micro-tecnología y nanociencia de la Universidad de Chalmers, liderado por el Dr. Samuel Lara, dirige los esfuerzos hacia el pertinente desarrollo de electrónica, fotónica, bio y nano sistemas avanzados.

De todos aquellos materiales que se pueden explorar del sistema de compuestos químicos, se tiene un interés particular por la generación eficiente de grafeno, y el desarrollo de cristales a partir de los cuales se logre extraer dicho material a través de crecimiento epitaxial u otros métodos de fabricación que resulten eficientes.

Antecedentes

Cómo se planteó en los documentos iniciales del proyecto, existe un contraste importante entre los métodos tradicionales de diseño de materiales.

Proceso tradicional de diseño de materiales

El proceso tradicional de diseño de nuevos materiales es el siguiente:

1. Se utiliza una base de datos de estructuras candidatos y se buscan aquellos que cumplan con las restricciones del material objetivo, por ejemplo, que contenga litio y que tenga una alta conductividad de Li-Ion.
2. Se procede a una fase de simulación en dónde se valida la viabilidad de las estructuras encontradas (usualmente entre 10-100k candidatos) y se estima si se mantendrá estable en el sistema físico real.
 - a. Las simulaciones son en realidad aproximaciones por la complejidad que implica simular la estructura completa en un sistema físico. Aun así, éstas resultan siendo computacionalmente costosas, de larga duración y con un grado considerable de error. Ejemplo de ello son *Density Functional Theory* (DFT).
3. Se obtienen 5-10 materiales candidatos que son enviados al laboratorio para síntesis experimental.




Fig. 1: Ejemplo de proceso tradicional de diseño de materiales con métodos basados en búsqueda.

Proceso de diseño de materiales con IA

Con el auge de la inteligencia artificial en sus diferentes frentes, se han liberado modelos especializados en el área de diseño de materiales. Las dos áreas más prominentes en las cuales se enfocan estos modelos son en:

- Modelos generativos de materiales
- Emuladores basados en IA

Estos dos tipos de modelos nos permiten re-imaginar el proceso tradicional de diseño de materiales. El proceso se podría desglosar en los siguientes puntos:

1. Se utilizan modelos generativos para “imaginar” nuevos materiales dada una serie de restricciones.
2. Se emulan los materiales generados para descartar su inviabilidad mediante un proceso eficiente.

Se obtienen 5-10 materiales candidatos que son enviados al laboratorio para síntesis experimental.

Tesis central

Los modelos generativos basados en algoritmos de difusión son capaces de generar una amplia gama de materiales, sin embargo, no someterlos a un proceso de afinación conduce a la generación de una gran proporción de materiales inviables en un sistema físico real.

Por lo anterior, lo que se requiere es un proceso de generación y filtrado de alto rendimiento.

Retos en la generación de materiales con modelos de difusión

Para la generación de materiales se eligieron dos modelos de difusión:

- MatterGen
- DiffCSP

A pesar de que ambos modelos ofrecen funcionalidades interesantes y son computacionalmente impresionantes en comparación con métodos de búsqueda y simulación convencionales, las estructuras de salida de SI-C frecuentemente colapsan o son inestables termodinámicamente bajo restricciones físicas cercanas a las reales.

Es por esto por lo que el proyecto tuvo un cambio de paradigma en su acercamiento. La estrategia original de generación de precisión, es decir, esperar que los cristales generados fueran perfectos y tuvieran los atributos de interés, fue sustituida por una generación de alto volumen, combinada con un filtrado rápido y agresivo de cristales inadecuados.

Proceso de trabajo para la generación y filtrado de materiales en automático




Fig. 1: Vista funcional del diseño del proceso (pipeline)

En la solución integral se trabajan sobre los componentes mostrados en la figura 1.

En un módulo encargado de la inferencia, se ejecuta un proceso secuencial de generación, simulación y evaluación.

En un segundo módulo se mantiene y administra el almacenamiento de resultados y de blobs de imágenes, tanto en crudo como procesados, así como un registro de auditoría para mantener el linaje de los datos producidos.

En un tercer y último módulo se presenta un gestor gráfico, sobre el cuál los usuarios podrán interactuar con el proceso completo.

Inferencia

Generación

La generación de cristales inicialmente ocurre aquí, a través del uso y parametrización de modelos de difusión como MatterGen. Los archivos de salida contienen información cristalográfica según el estándar ASE.

Simulación

Se simulan relajaciones básicas a través de algoritmos de optimización básicos y se utilizan emuladores atomísticos para estimar las propiedades físicas resultantes como lo son MatterSim y NVIDIA Alchemi.

Evaluación

Se crean visualizaciones automáticamente que son inspeccionadas por un modelo de Visión-Lenguaje para la identificación de anomalías estructurales evidentes que los modelos matemáticos pueden pasar por alto.

Almacenamiento

Datos de cristales

Se almacenan los datos que los trabajos terminados han producido, esto incluye un manifiesto de cada etapa.

Blobs

Las visualizaciones generadas por el módulo de inferencia se almacenan directamente de manera no-estructurada en un lago o almacén de datos crudos.

Gestor

Gestión y configuración de proceso

Permite al usuario decidir entre el modelo y parámetros de generación, simulación y criterios de evaluación. También permite configurar características de trabajo, cómo la cantidad o tiempo de inferencia, la composición química y otras restricciones en tiempo de ejecución.

Visualización y anotación de resultados

Permite la selección de cristales producidos de interés, su visualización y anotación. Se presente utilizar esta herramienta para un proceso de curaduría manual para la elección

de cristales que serán candidatos a simulaciones avanzadas o a pertenecer a un conjunto de entrenamiento para afinación.

Hallazgos claves y conclusiones

En síntesis, el proyecto establece una base sólida para la exploración automatizada de materiales mediante inteligencia artificial, alineada con el interés del grupo de investigación en la generación eficiente de grafeno y cristales precursores. Los resultados obtenidos sientan las bases para trabajo futuro orientado a la afinación de modelos, la incorporación de simulaciones de primeros principios y la expansión del pipeline con modelos generativos y de simulación adicionales.

Trabajo futuro

- Evaluación de eficacia y ajuste de criterios LLM Judge
- Validación por primeros principios
- Afinación de modelo
- Introducción de modelos adicionales para generación
- Introducción de modelos adicionales para simulación