



**Tecnológico
de Monterrey**

Resumen ejecutivo del proyecto

Proyecto Integrador

Patrocinadores:

Dr. Juan Arturo Nolazco Flores

Dr. Samuel Lara Ávila

Integrantes:

Javier González Aces - A01274650

José Alejandro Cortés Pérez - A01795033

Osiris Xcaret Saavedra Solís - A01795992

Fecha de entrega: 15 de marzo del 2026

Generación y evaluación de estructuras cristalinas mediante modelos de difusión, con enfoque futuro en materiales relevantes para crecimiento de grafeno

1. Propósito general del proyecto

Este proyecto integrador busca explorar el uso de modelos generativos de inteligencia artificial para materiales cristalinos, mediante la implementación del modelo generativo DiffCSP mediante una implementación inicial, controlada y reproducible. El objetivo actual es construir una base experimental sólida que permita avanzar de forma técnicamente justificable hacia la predicción de materiales óptimos para crecimiento de grafeno.

En su estado presente, el proyecto se enfoca en responder una pregunta intermedia pero crucial:

¿Es posible construir un pipeline reproducible que aprenda a generar o reconstruir estructuras cristalinas reales a partir de un modelo generativo por difusión, y evaluarlo con métricas tanto de machine learning como estructurales?

Ese objetivo intermedio es importante porque el problema final es mucho más complejo y requerirá, información de superficies, estabilidad, física local, orientación cristalográfica y posiblemente propiedades termoquímicas o de proceso. Por eso, el proyecto parte de una fase basal: aprender primero a reproducir materiales reales y físicamente plausibles, empezando con sistemas cercanos a carburo de silicio (SiC).

2. Motivación científica y dirección estratégica

La motivación de fondo del proyecto está vinculada al diseño de materiales y, más específicamente, a materiales sobre los que pueda ser viable crecer una capa de grafeno. En la conversación se estableció que SiC tiene un papel central como punto de partida, porque representa un sistema materialmente relevante para grafeno epitaxial y, además, sirve como familia inicial manejable para validar el pipeline.

A partir de ello, la estrategia científica del proyecto se puede entender en tres escalones:

Primero, demostrar que el pipeline puede leer estructuras cristalinas reales, entrenar un modelo generativo y producir salidas evaluables.

Después, demostrar que ese pipeline puede reproducir materiales reales o distribuciones estructurales plausibles, preferentemente en dominios químicamente coherentes como SiC o familias similares.

Finalmente, utilizar ese conocimiento como fundamento para una versión más avanzada del sistema, orientada a materiales candidatos para formación de grafeno.

3. Estado actual: Fase 1: Baseline reproducible

Actualmente el proyecto está en fase 1. Esto significa que se priorizó una implementación simple, controlada y auditable, antes de introducir complejidad arquitectónica o física.

La arquitectura del proyecto sigue una lógica del estilo artículo de investigación reproducible, con separación de funciones, archivo de configuración, outputs versionados por corrida y métricas consistentes. Los archivos principales son:

- Beta_1.py: script principal del pipeline.
- data_utils.py: utilidades de seeds, device, split y listado de CIFs.
- metrics.py: métricas estructurales.
- baselines.py: modelos baseline.
- evaluation.py: evaluación por estructura y agregación.
- config.yaml: configuración reproducible del experimento.

4. Qué hace técnicamente el pipeline actual

El flujo implementado hoy es el siguiente:

1. Lee estructuras cristalinas desde archivos CIF.
2. Extrae tres componentes básicos:
 - coordenadas fraccionales (frac_coords),
 - números atómicos (atomic_numbers),
 - matriz de red (lattice).
3. Define un proceso de difusión tipo DDPM con un esquema de ruido lineal (beta schedule) y una función q_sample para perturbar coordenadas fraccionales.
4. Entrena un modelo simple que aprende a predecir el ruido agregado.
5. Ejecuta un proceso de reverse diffusion simplificado para generar una nueva estructura cristalina.
6. Evalúa cada estructura generada con métricas de:

- predicción de ruido,
- validez geométrica básica,
- densidad,
- similitud estructural vía RDF.

7. Exporta las mejores estructuras válidas en formato CIF para inspección visual, por ejemplo, en VESTA.

Esta implementación es simple y no pretende ser todavía una versión completa de DiffCSP. Aún no se incluyen neighbor lists, GNNs, EGNNs, simetrías cristalinas, estabilidad energética, restricciones físico-químicas avanzadas ni modelado de la celda cristalina.

5.1 Baseline trivial

El baseline más simple es la predicción nula del ruido ($\hat{\epsilon} = 0$). Este baseline establece el piso mínimo de desempeño. Si el modelo generativo no logra superar esto, todavía no está aprendiendo algo útil. El código del baseline cero está definido como un MSE contra cero.

5.2 Baseline de machine learning tradicional: Ridge

Se implementó un modelo Ridge Regression que predice el ruido a partir de features muy simples por átomo:

- coordenadas perturbadas x_t ,
- tiempo normalizado t/T ,
- número atómico Z .

La motivación aquí es doble:

- tener una referencia interpretable y lineal,
- evitar que el modelo generativo parezca “bueno” solo por compararse contra un baseline demasiado débil.

Ridge constituye un análogo útil de “ML tradicional” frente al modelo generativo. En el proyecto ya está integrado formalmente, tanto para entrenamiento como para evaluación comparativa.

5.3 Baseline generativo: DDPM simplificado

El baseline principal del proyecto es un modelo generativo tipo DDPM simplificado, cuyo denoiser es una red DummyDenoiser basada en MLP. Esa red:

- embebe el número atómico,
- concatena coordenadas perturbadas,
- concatena una representación escalar del tiempo,
- predice el ruido atómico por partícula.

Este modelo es útil como punto de partida, pero conceptualmente limitado porque no modela interacciones entre átomos, no construye grafos, no usa vecinos y no incorpora inductive biases geométricos o físicos.

6. Métricas del proyecto

El proyecto distingue correctamente entre métricas proxy de ML y métricas estructurales.

6.1 Métricas proxy de machine learning

La evaluación incluye:

- mse_eps_model
- mse_eps_zero
- mse_eps_ridge
- mejoras relativas contra cero y contra Ridge.

Estas métricas miden qué tan bien el modelo predice el ruido del proceso forward. Son útiles para entrenamiento y comparación, pero indirectas respecto al objetivo físico real.

6.2 Métricas estructurales

La evaluación estructural incluye:

- valid: si la estructura cumple criterios básicos,
- min_dist: distancia interatómica mínima,
- density: densidad resultante,
- rdf_l1: distancia entre la RDF de la estructura generada y la RDF de la referencia.

La validez básica se determina verificando que:

- la distancia mínima entre átomos no caiga por debajo de un umbral,
- la densidad permanezca en un rango aceptable.

La RDF se usa como medida de similitud estructural entre la muestra generada y el cristal real, lo cual tiene sentido porque captura información sobre la distribución de distancias interatómicas.

6.3 Criterio real de calidad

En el proyecto quedó establecido que la calidad real del pipeline no se debe juzgar únicamente por MSE, sino principalmente por la combinación de Validity Rate y RDF error.

7. Outputs del pipeline

Cada ejecución genera un directorio fechado tipo:

results/runs/run_YYYYmmdd_HHMMSS/

y dentro guarda:

- config_used.yaml
- model.pt
- train_log.csv
- eval_rows.csv
- eval_summary.csv
- valid_index.csv
- valid_structures/

Esto tiene valor científico porque cada corrida queda trazable y reproducible. config_used.yaml preserva la configuración exacta usada; train_log.csv deja el historial de entrenamiento; eval_rows.csv y eval_summary.csv documentan el desempeño a nivel muestra y a nivel agregado; y valid_structures/ permite una inspección visual de resultados estructuralmente aceptables.

Además, el pipeline ya implementa exportación Top-K de estructuras válidas, ordenadas ya sea por rdf_l1 o por un score compuesto configurable que combina RDF, distancia mínima y densidad. Esa lógica está implementada en Beta_1.py.

8. Ejecución de prueba en Colab

El proyecto ya fue ejecutado en Google Colab como prueba end-to-end. La corrida reportó:

- uso correcto de GPU (Device: cuda),
- split en train, val, test,
- entrenamiento de épocas seleccionable,
- construcción del baseline Ridge con dataset supervisado para X y para y,
- evaluación completa en train, val y test,
- exportación de estructuras Top-K válidas.

Las ejecuciones quedan guardadas en Drive, con CIFs válidos listos para abrir en VESTA.

9. Interpretación resultados

El resultado operativo de las ejecuciones en colab fue exitoso: el pipeline se ejecuta de extremo a extremo, sí entrena, sí evalúa y sí exporta estructuras válidas.

Desde el punto de vista científico, el desempeño del modelo sigue siendo débil pero informativo. La loss de entrenamiento subió entre épocas lo que sugiere que el baseline actual aún no aprende de forma estable. Además, el modelo no supera consistentemente al baseline trivial ni a Ridge en todos los splits. En test hay una mejora pequeña frente a cero, pero en train y val no se observa una ventaja robusta.

Aun así, estructuralmente el resultado no es despreciable:

- la tasa de validez ronda entre 40% y 50%,
- el `rdf_l1` está en torno a 0.18–0.19,
- se exportaron estructuras válidas.

Por lo que: el baseline reproducible ya funciona como pipeline experimental, pero el modelo generativo simplificado todavía no muestra una ventaja clara y consistente frente a baselines simples.

10. eval_rows.csv

`eval_rows.csv` permite bajar el análisis al nivel de estructura individual. Se observó que el modelo no se comporta igual en todos los materiales. Hay muestras donde gana frente a cero o frente a Ridge, y otras donde pierde claramente. También se confirmó

una tasa global de validez alrededor de 44–45% y un conjunto de CIFs exportados que constituyen el subconjunto más útil para inspección visual.

La lectura más importante de eval_rows.csv es que el modelo actual es heterogéneo e inestable a nivel muestra individual, lo cual refuerza la idea de que todavía se trata de un baseline inicial. Sin embargo, también deja claro que ya existe un subconjunto de estructuras razonables sobre el cual se puede trabajar, comparar y visualizar.

11. Dataset

Un hallazgo importante durante la exploración fue que muchas de las muestras descargadas de Materials Project empezaban con “Ac”, lo que indicaba que el muestreo no estaba alineado con el objetivo del proyecto. Es decir, no basta con descargar materiales “estables” al azar; lo ideal es filtrar el dataset de Materials Project para que sea químicamente coherente con el problema, sin embargo, mientras más exigente se sea con los criterios para obtener los materiales, menos muestras se conseguirán, haciendo que el modelo cuente con poca información para entrenar y en consecuencia no pueda obtener un buen rendimiento. Se necesita estudiar mejor el equilibrio entre homogeneidad y tamaño del dataset.

12. Nueva orientación del dataset

A partir del punto anterior se definió una estrategia más adecuada para construir el dataset. La recomendación principal fue filtrar Materials Project hacia alguna de estas tres escalas:

Dataset 1: SiC puro

Usar chemsys="Si-C" para trabajar únicamente con el sistema químico silicio-carbono. Esto es ideal para validar si el pipeline puede aprender materiales muy cercanos al objetivo inicial.

Dataset 2: familia tipo SiC

Ampliar el conjunto a sistemas químicamente afines como Si-C, C, Si, Si-Ge, B-C, B-N, Al-N, Ga-N.

Esto permite más variedad sin perder coherencia estructural y química.

Dataset 3: semiconductores cristalinos simples

Usar materiales estables o casi estables, con pocos elementos y excluyendo química irrelevante como actínidos o lantánidos, para formar un conjunto más amplio, pero aún razonable para una fase temprana.

La lógica de esta estrategia es primero aprender un dominio químico estrecho y relevante, luego ampliar gradualmente.

13. Limitaciones actuales del proyecto

El proyecto tiene varias limitaciones reconocidas y explícitas.

La más importante es que el modelo DummyDenoiser no incorpora la estructura relacional del cristal. Cada átomo se trata básicamente de forma local, sin vecindarios ni interacciones atómicas explícitas, lo que limita su capacidad para capturar física real de materiales.

Además, el reverse diffusion implementado es simplificado y no incorpora mecanismos más ricos de reconstrucción cristalina.

Tampoco se está modelando todavía, energía, estabilidad, simetrías, periodicidad de manera rica, construcción de la celda, propiedades de superficie, propiedades relevantes para grafeno.

Otra limitación importante es la del dataset: entrenar con materiales químicamente heterogéneos o irrelevantes introduce ruido conceptual y dificulta el aprendizaje.

14. Próximos pasos

Corto plazo

- Cambiar el dataset hacia **SiC** o **SiC-like**.
- Repetir ejecuciones pequeñas con química más coherente.
- Revisar visualmente los CIFs exportados.
- Analizar eval_rows.csv de forma más dirigida.

Mediano plazo

- Estabilizar el entrenamiento del baseline.
- Probar más épocas, menor learning rate y datasets más homogéneos.
- Mejorar el modelado del tiempo y revisar detalles de implementación.

Fase 2

- Introducir neighbor lists y modelos tipo GNN.
- Moverse hacia arquitecturas más compatibles con física local del cristal.

Fase 3

- Agregar componentes físicos: energía, estabilidad, restricciones estructurales.

Fase 4

Reorientar el sistema hacia diseño inverso y, eventualmente, hacia la predicción de materiales compatibles con crecimiento de grafeno.

17. Conclusión

En síntesis, este proyecto construye una plataforma experimental reproducible para generación de estructuras cristalinas mediante difusión, inspirada en DifCSP pero implementada, por ahora, como un baseline simplificado. El pipeline ya funciona de extremo a extremo: lee CIFs, entrena un modelo DDPM básico, compara contra baselines trivial y Ridge, evalúa métricas de ruido y de estructura, y exporta las mejores muestras válidas para inspección visual.

Los resultados actuales muestran que el proyecto ya es operativamente exitoso, aunque el modelo generativo aún no sea científicamente competitivo. La señal principal es que la infraestructura y la metodología ya están en su lugar, pero el desempeño del baseline todavía es limitado, lo cual es coherente con el nivel de simplificación de la arquitectura y con la necesidad de refinar el dataset.

El siguiente paso estratégico correcto no es aumentar complejidad indiscriminadamente, sino alinear el dataset con el objetivo científico, comenzando por sistemas tipo SiC y familias similares. Esa reorientación permitirá que el pipeline deje de aprender sobre materiales irrelevantes y empiece a trabajar sobre distribuciones más cercanas al problema real. Desde ahí, el proyecto podrá evolucionar hacia modelos geométricos y físicos más ricos, y eventualmente hacia el objetivo de mayor valor: apoyar el descubrimiento o evaluación de materiales con potencial para favorecer formación de grafeno.